階段性成果檢視 · WEEK 01–07 + PDF 預檢 v0.8

作業規格與缺漏檢查助手

以老師範例為參考，交作業前先指出哪些已完成、哪些需要補件、哪些要等老師確認。

已完成　需補件　待確認

第 02 組

陳冠友 S11259039 （隊長）　林崇瑋 S11259031 （隊員）



證據 10–28 / 30 、 11–04 · W7 6a5bc9b · PDF 13b2b1e · W6 327b7e2 · 示範與腳本用合成資料

問題與使用情境

學生交作業前，常常不知道少了哪一段

誰會用、怎麼用

老師
提供範例與已確認的必做要求

學生
交報告前先貼上或上傳，自我檢查

老師與學生
學生看補件建議，老師看有引用的待確認項

同樣「有寫」，判斷可能不同

「誰會用」寫成：擔心漏寫的南大同學 — 已完成

語意符合，標題不同不算缺交

失敗案例只有「輸入」與「實際結果」 — 需補件

缺少失敗原因，提醒補上

寫「測試紀錄見附錄 A」，但讀不到附錄 — 待確認

無法確認，交由老師核對

標題與用字都會變，關鍵字規則判不準，所以需要 LLM 判讀語意。

七週累積：三條路徑都已實作，但還沒接在一起



A 文字語意比對

老師規格＋學生文字 → GPT 判讀是否符合，系統核對原文引用

LIVE_PASS

B 補件工具流程

GPT 提出工具呼叫 → Host 驗證 → 使用者確認後寫入草稿

LIVE_PASS

C PDF 預檢與估分

老師與學生 PDF 圖文比對，確認配分後才顯示估分；腳本實測用合成 PDF

腳本 4 過、手動 2 敗

最大缺口：A、C 的判讀結果尚未接入 B 的草稿工具，B 目前讀的是預先撰寫的合成評閱快照。

LLM 判讀語意，程式負責把關

交給模型

需要理解語意的判斷

- 理解換句話說：標題不同，內容是否仍符合
- 判斷充分性：有寫，但是否寫完整
- 讀 PDF 文字與圖片，選出證據行號
- 提出工具呼叫與修改建議

交給程式

可以明確驗證的規則

- 欄位、版本、要求覆蓋與大小限制
- 原文引用、頁碼與來源 hash 核對
- 權限、人工確認與 Session 隔離
- SQLite 交易、同 ID 冪等、配分加總

單次比對不需要 Agent ；「查詢後提案、確認後執行、再回填結果」才需要受控的工具流程。

模型只提出動作，Host 決定能不能執行



工具結果回填模型後，Host 再核對摘要才回傳 UI 。

Session 記憶只提供背景，不能授權寫入。

兩個工具都有可驗證的輸入、輸出與停止點

get_submission_review

唯讀 · MCP

輸入	作業 ID 、提交 ID 、版本
輸出	缺漏、待確認項、引用與 hash
驗證	目標一致、來源有效、完整覆蓋
傳輸	MCP stdio ，只能讀

create_revision_draft

寫入 · 需確認

輸入	相同目標＋ requirement_ids
輸出	draft_id 、 request_id 、收據
驗證	項目一致、來源未變、使用者確認
寫入	本機 SQLite ，同 run ID 只寫一次

3 輪 模型呼叫上限

2 次 可重試錯誤上限

10 分鐘 提案確認期限

非法參數、工具順序不符、引用不足或無權限 → 立即停止、不寫入，疑義交給老師。

清除對話後，舊摘要不再進入模型

成功報告

摘要通過 Host 核對

→

本 Session 最近一筆摘要

≤ 4,096 bytes ，不含原文與先前同意

→

下次模型 context

先核對 owner 與來源版本

三種情況會切斷記憶

- 清除對話，開始新 Session
- 換成另一位使用者
- 來源更新為 v2 （hash 改變）

→ context 回填 memory: null ，舊提案失效

清除 ≠ 刪除：既有草稿、交易與稽核紀錄仍保留在本機。

▼本次記憶範圍

只保存本 Session 最近一次成功摘要。換身分、新 Session 或來源更新後，舊摘要不進入模型 context。摘要不代替新的來源查詢或寫入同意。


```
{
  "kind": "untrusted_prior_report_data",
  "memory": null,
  "trace": {
    "scope": "session",
    "session_id": "session-9515e61a2e944d578ddccdd7d735b8f0",
    "owner_id": "student-a",
    "source_version": "synthetic-review-
v1:2bb0fd672501cde20cbdd481a3d381713d3540651be84ca8cf081bcf976d7dfa",
    "stored_source_version": null,
    "included": false,
    "reason": "empty_session",
    "report_hash": null
  }
}
```


實際畫面：清除後的新 Session （2026-10-28）

示範：使用者按下確認後，才寫入一份草稿

1	提出補件需求	使用者
2	呼叫查詢工具 get_submission_review	GPT
3	驗證參數、查來源並回填結果	Host
4	提出草稿工具（此時尚未寫入）	GPT
5	**按下確認，Host 才寫入 SQLite**	使用者
6	收據回填 GPT ，核對摘要後回傳	Host

LIVE_PASS **草稿 1 份；同一請求重送仍是 1 份**



語意比對分得出「有寫」和「寫完整」

老師要求：說明使用者與情境，並提供含輸入、結果與原因的失敗案例。

已完成 **R1　使用者與情境**

標題寫「誰會用」，仍清楚描述對象與情境 → 符合

需補件 **R2　完整的失敗案例**

有輸入、有實際結果，但沒寫失敗原因 → 部分完成

系統只確認引用確實存在於原文，不保證語意判斷正確；模型建議的失敗原因也需學生自行查證。



v0.8 新功能

PDF 預檢：模型挑證據行號，Host 複製原文

1 使用者
上傳兩份 PDF
老師規格 / 範例＋學生報告

→

2 Host
驗證並標上行號
檢查大小與頁數，擷取文字並逐行編號

→

3 GPT
圖文一起判讀
讀文字與頁面圖片，比對語意，選出證據行號

4 Host
複製原文核對
依行號取引文，驗證頁碼、配分與分數範圍

→

5 使用者
確認老師配分
勾選核對後，才看得到估分

→

6 Host
加總估分區間
產生本機報告，可下載 JSON

估分只在三個條件都成立時才顯示

老師原文明列配分 → 總和 = 100 → 使用者已確認 → 顯示估分區間

否則只列缺漏與待確認項，不產生分數。

選擇這次作業的兩份 PDF

老師的作業規格 / 範例 PDF

選擇檔案 未選擇任何檔案

學生準備繳交的報告 PDF

選擇檔案 未選擇任何檔案

每份上限 6 MiB、25 頁，兩份合計 35 頁。請確認老師與學生檔案沒有放反。

用 GPT 檢查這兩份 PDF

按下後會將兩份 PDF 傳至 OpenAI，使用 API 額度。原 PDF 不存入資料庫，檢查報告保存在本機 Session 紀錄。

目前只檢查 PDF，沒有編譯 C++ 或驗證原始圖片檔。缺少原始檔的部分會列為待確認，避免直接判定沒交。

v0.8 新功能

前兩版失敗被擋下；換 gpt-5.4 仍會失敗、也會誤判

ae1a441 LIVE_FAIL

gpt-4.1-mini 直接寫引文

模型把摘要當成逐字引文，還混用頁碼。

`UNGROUNDED_PDF_REPORT`

Host 拒絕輸出成績

→

a9010bf LIVE_FAIL

改成模型選行號、Host 複製

模型選了跨頁、過長的範圍；人工抽查也發現目錄被當成正文。

`INVALID_SOURCE_REFERENCE`

引用被擋下，未給分

→

13b2b1e 腳本 4 過、手動 2 敗

PDF 改用 gpt-5.4

腳本（c0403a3、327b7e2）4 次通過，預期只中 6 / 7；11/4 手動 2 次回 502。

`gpt-5.4-2026-03-05`

引用仍可能錯，語意也會錯

學到的事：三層要分開驗證

格式通過 ≠ 引用正確 ≠ 語意判斷正確

實測：模型說學生第 2 頁有終端機截圖，實際沒有，Host 核對仍放行。

Week 6 ：系統指出錯處，再請 GPT 修訂一次

1 GPT
草稿 A
讀兩份 PDF ，選證據行號

→

2 Host
逐項評估
最終關卡同一套規則，列出問題與位置

→

3 GPT
修訂得到 B
帶著 A 與問題清單，只改被指出處

→

4 Host
同規則重評
並禁止把推測改成明確要求

→

5 結果
通過才採用
仍未通過：第 2 份即停，不給分

草稿 A 通過就直接採用，呼叫次數與原版相同；判斷檔案放反不修訂；模型服務錯誤不重試。

真實比較：腳本每版每輪各一次，另加彩排手動兩次

gpt–5.4 · 6 次

✓ 腳本 4 過　✗ 手動 2 敗

腳本都是第一份通過，候選沒多呼叫，但 7 項預期只中 6 項；手動失敗原因未明。

gpt–4.1–mini · 兩輪

✗ 原版 LIVE_FAIL　✗ 候選 LIVE_FAIL

候選的修訂稿兩次都與 A 逐字相同，到上限停止； tokens 約 2.3 倍。

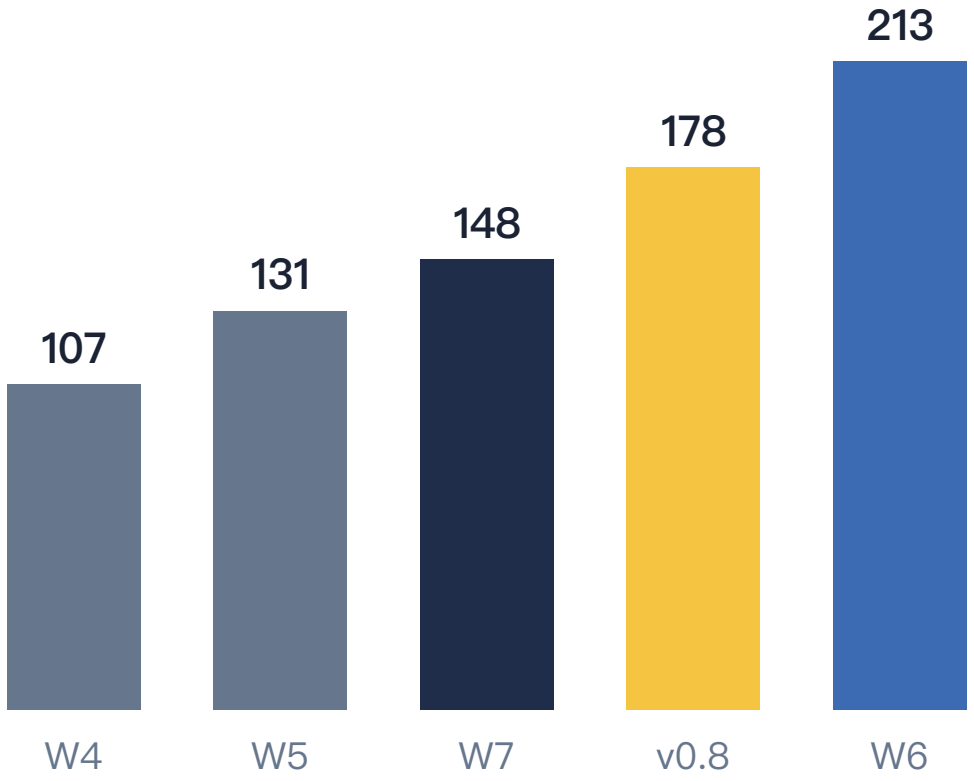
離線 15 個案例

✓ 15 / 15 符合預期

修訂後通過、到上限停止、檔案放反不修訂、改標推測被拒。

尚未證明改善　**預設維持原版，候選可在工作台切換。下一步：用 gpt–5.4 測修訂路徑，並把草稿 A 改放 user 訊息重測。**

回歸測試從 107 項成長到 213 項



v0.8 新增 30 項 PDF 測試，W6 （10/30 補交）再加 35 項。
全部是離線與故障注入，不等於真實模型準確率。

關鍵案例：預期與實際一致

同 Session 續問	帶入該 Session 的摘要	GPT
清除後新查詢	memory:null ，任務仍完成	GPT
跨使用者讀取	RUN_NOT_FOUND	HTTP
同 ID 重送	確認後與重送都是 1 份	GPT
非法參數、 429	有限停止，不新增草稿	故障注入
PDF 錯誤引用、到上限	不估分，第 2 份即停	離線

真實呼叫用量（不是帳單）：Week 7 共 14 次模型回覆、18,296 tokens ；
Week 6 腳本 10 次回覆、86,451 tokens （手動 2 次未取得）。

保留一個真實失敗：模型略過了草稿提案

兩者的檢索與引用 gate 都是 ready ，且使用同一個 evidence hash 。

原版

LIVE_FAIL

讀取後直接回答，跳過提案工具； Host 以 UNEXPECTED_TOOL_SEQUENCE 擋下，未寫入。

2	2,133	6.518 s
次模型回覆	tokens	觀測時間

Session 候選

LIVE_PASS

依序提案、等待確認，使用者確認後完成草稿。

3	4,352	5.183 s
次模型回覆	tokens	觀測時間

只有一組樣本，而且兩者完成的終點不同：不能宣稱記憶提升了品質或降低成本。

課程要求的 Google Cloud / ADC Gemini ： LIVE_NOT_RUN ；本專案全程使用 OpenAI GPT ，不能拿來替代。

下一步：把判讀結果接進草稿工具

已完成且已驗證

- 文字語意比對： LIVE_PASS
- 補件工具流程： LIVE_PASS
- Session 清除與跨人隔離

已實作，效果待證明

- W6 評估後修訂：未證明改善
- PDF ：腳本 4 過、手動 2 敗
- 來源 v2 僅離線；估分未校準

規劃中（期末前）

- P0 判讀結果接入草稿工具
- P0 20 組教師標註案例
- P1 補 Gemini / ADC 驗證、OCR 、正式登入

驗收： 20 組標註案例 · 跨人隔離 · 來源變更拒寫 · 可重現 trace ，並分開報告正確率與拒答率。

團隊與後續

分工與問答

陳冠友

S11259039 · 隊長

建議主講

後端、工具確認、 Session 記憶與 PDF 預檢示範

林崇瑋

S11259031 · 隊員

建議主講

使用情境、來源引用、測試與失敗分析

以上是建議分工，實際貢獻待兩位確認；開發、測試與簡報製作有使用 AI 工具（Codex 、 Claude）協助。

簡報＋示範 14 分鐘	問答 5 分鐘	緩衝

共 20 分鐘

謝謝，歡迎提問